R七种武器之网络爬虫RCurl 第1周

法律声明

【声明】本视频和幻灯片为炼数成金网络课程的教学资料，所有资料只能在课程内使用，不得在课程以外范围散播，违者将可能被追究法律和经济责任。

课程详情访问炼数成金培训网站

http://edu.dataguru.cn

关注炼数成金企业微信

- 提供全面的数据价值资讯，涵盖商业智能与数据分析、大数据、企业信息化、数字化技术等，各种高性价比课程信息，赶紧掏出您的手机关注吧！

数据分析三步走

- 数据抓取
- 数据加工
- 数据可视化

R七种武器之

- 数据抓取

  ------？

- 数据加工

  ------金融数据分析quantmod、数据加工厂plyr

- 数据可视化

  ------数据可视化包ggplot2、交互化展示包shiny

巧妇难为无米之炊！

- 如何获取数据呢？
  - 手动输入？
  - 别人给予？
  - ……
- 不若自己去获取！

RCurl的作者

- Duncan Temple Lang

现任加州大学 U.C. Davis分校副教授

致力于借助统计整合进行信息技术的探索

其omega团队已开发程序包达50余个

包括RCurl、XML、RSPython、Rmatlab等

作者个人主页：http://anson.ucdavis.edu/~duncan/

RCurl的概述

- The RCurl package is an R-interface to the libcurl library that provides HTTP facilities. This allows us to download files from Web servers, post forms, use HTTPS (the secure HTTP), use persistent connections, upload files, use binary content, handle redirects, password authentication, etc.

- RCurl这个程序包提供了由R到libcurl库的接口，从而实现HTTP的一些功能。例如，从服务器下载文件、保持连接、上传文件、采用二进制格式读取、句柄重定向、密码认证等等。

RCurl

- 什么是curl&libcurl
  - curl：利用URL语法在命令行方式下工作的开源文件传输工具
  - curl背后的库就是libcurl
- 功能
  - 获得页面
  - 有关认证
  - 上传下载
  - 信息搜索
  - ……

必要的知识储备

- HTTP 协议
- 正则表达式

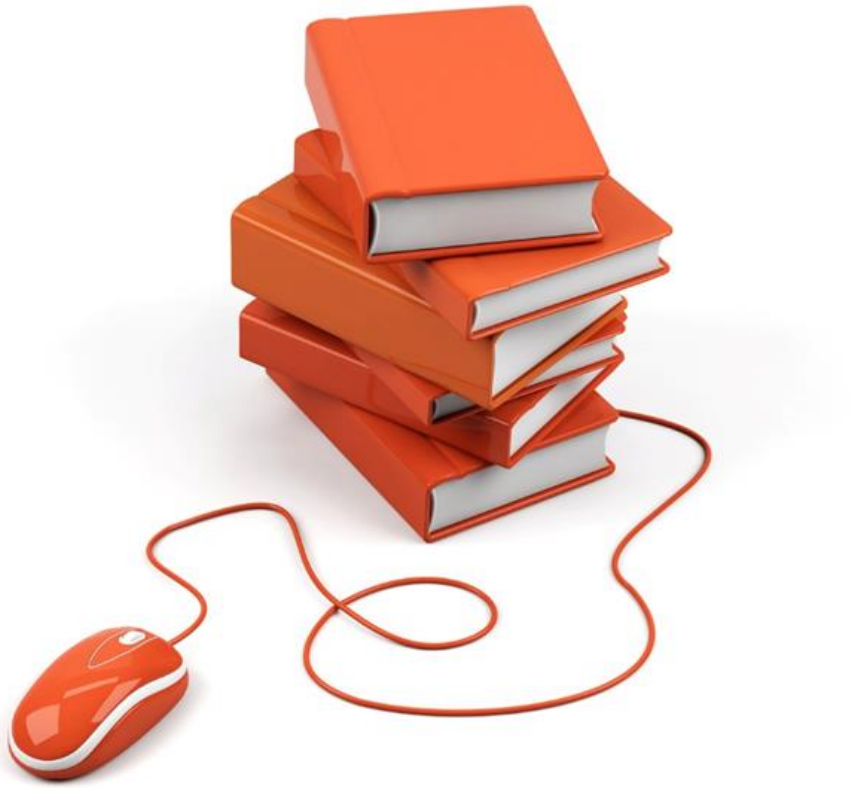

HTTP协议

- 协议是指计算机通信网络中两台计算机之间进行通信所必须共同遵守的规定或规则，超文本传输协议(HTTP)是一种通信协议，它允许将超文本标记语言(HTML)文档从Web服务器传送到客户端的浏览器

- 目前我们使用的是HTTP/1.1 版本

URL详解

- 基本格式：schema://host[:port#]/path/.../[?query-string][#anchor]

scheme	指定低层使用的协议(例如：http, https, ftp)
host	HTTP服务器的IP地址或者域名
port#	HTTP服务器的默认端口是80，这种情况下端口号可以省略。
path	访问资源的路径
query-string	发送给http服务器的数据
anchor-	锚

简要图解

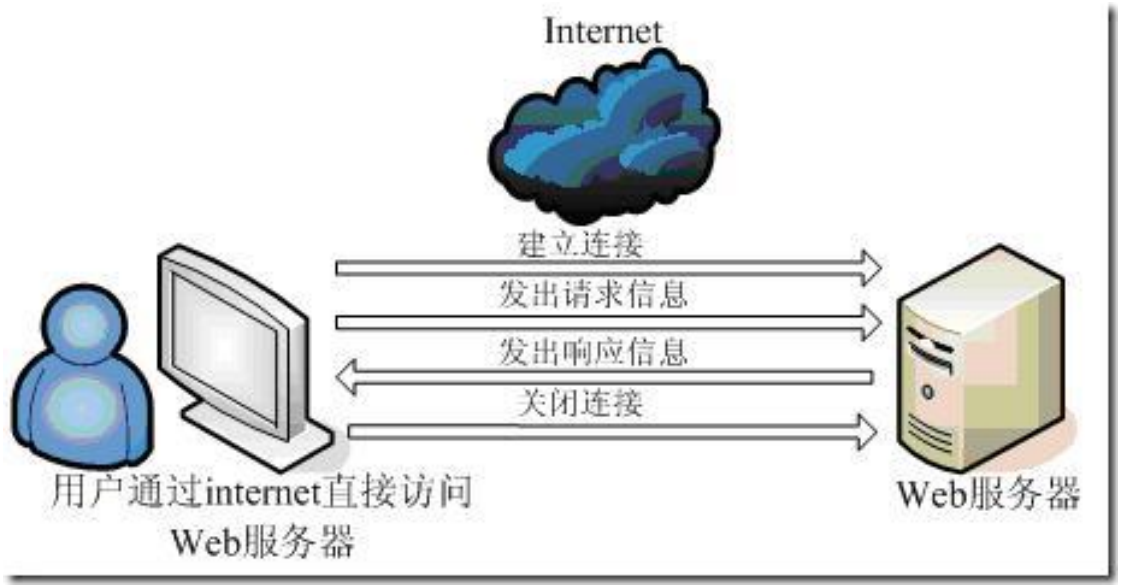
Internet
建立连接
发出请求信息
发出响应信息
关闭连接
用户通过internet直接访问
Web服务器
Web服务器

代理服务器的作用

- 1. 提高访问速度， 大多数的代理服务器都有缓存功能。
- 2. 突破限制， 也就是翻墙了
- 3. 隐藏身份

请求request

- 请求行、请求报头、消息正文

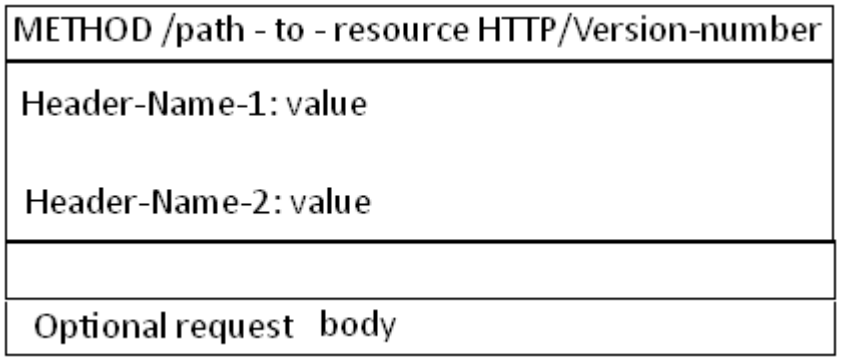

Method表示请求方法,比如“GET” ，“POST”，“ “HEAD” ，” PUT “等

Path-to-resource表示请求的资源

Http/version-number 表示HTTP协议的版本号

请求报头

- Host
- Accept
- Accept-encoding
- Accept-language
- User-agent
- Cookie
- Referer
- Connection

响应response

- 状态行、消息报头、响应正文

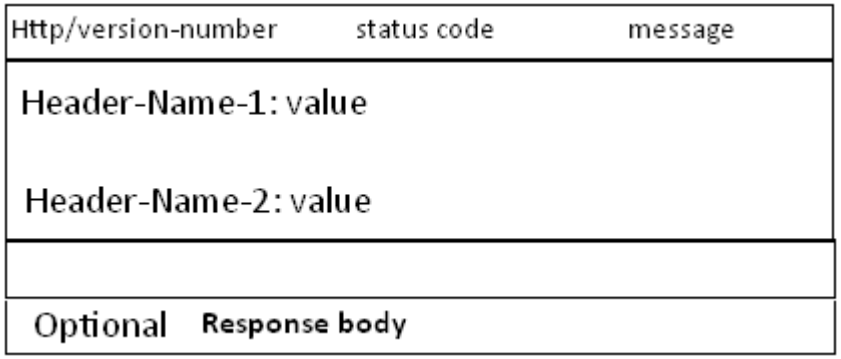

HTTP/version-number表示HTTP协议的版本号

status-code 和message表示状态码以及状态信息

状态码

- 状态码用来告诉HTTP客户端,HTTP服务器是否产生了预期的Response.
- HTTP/1.1中定义了5类状态码， 状态码由三位数字组成，第一个数字定义了响应的类别
  - 1XX 提示信息 - 表示请求已被成功接收，继续处理
  - 2XX 成功 - 表示请求已被成功接收，理解，接受
  - 3XX 重定向 - 要完成请求必须进行更进一步的处理
  - 4XX 客户端错误 - 请求有语法错误或请求无法实现
  - 5XX 服务器端错误 - 服务器未能实现合法的请求

消息报头

- Server
- Date
- Last-Modified
- Content-type
- Connection
- X-Powered-By
- Content-Length
- Set-Cookie

```
> k=getURL("http://www.dataguru.cn/",headerfunction = h$update)
> h$value()
                          Server                            Date
                         "nginx" "Tue, 05 Aug 2014 03:40:08 GMT"
                    Content-Type                  Content-Length
                     "text/html"                        "225561"
                   Last-Modified                      Connection
"Tue, 05 Aug 2014 03:10:01 GMT"                      "keep-alive"
                            Vary                            ETag
               "Accept-Encoding"             "\"53e04b09-37119\""
                   Accept-Ranges                          status
                         "bytes"                           "200"
                   statusMessage
                            "OK"
>
```

利用Firefox的插件来具体查看

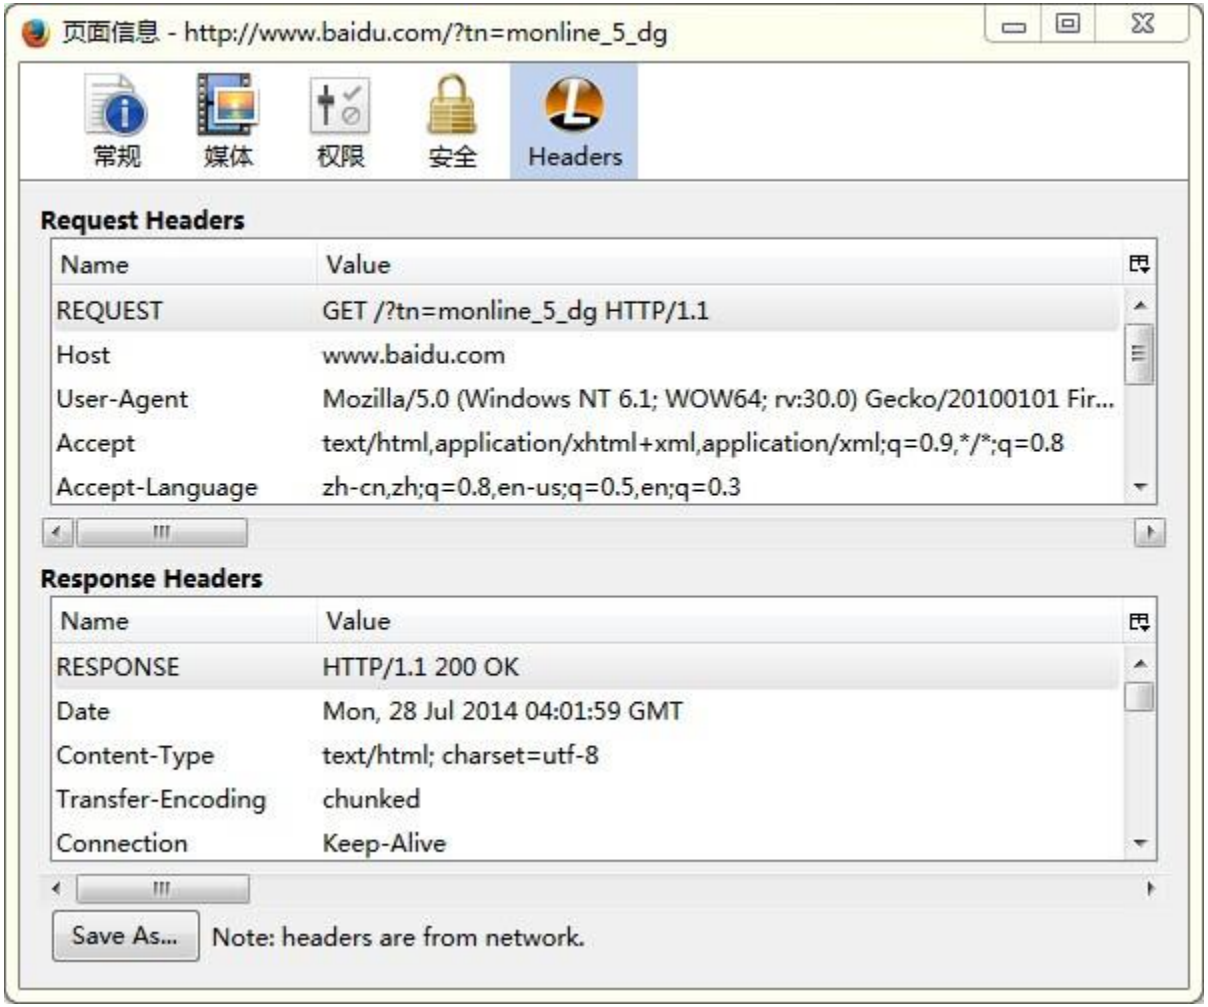

RCurl的三大函数

- getURL()
- getForm()
- postForm()

利用getURL()查看相关信息

- url.exists()

- d = debugGatherer()

```
temp <- getURL("http://www.dataguru.cn/",debugfunction=d$update,verbose = TRUE)
cat(d$value()[3])#提交给服务器的头信息
cat(d$value()[1])#服务器地址以及端口号
cat(d$value()[2])#服务器端返回的头信息
```

利用getURL()查看相关信息

- 查看服务器端返回的头信息
- ##字符串形式
- headers = basicTextGatherer()

txt=getURL("http://www.dataguru.cn/",headerfunction = headers$update)

names(headers$value())#说明是字符串形式

headers$value()

```
> ##字符串形式
> headers = basicTextGatherer()
> txt=getURL("http://www.dataguru.cn/",hea
> names(headers$value())#说明是字符串形式
NULL
> headers$value()
[1] "HTTP/1.1 200 OK\r\nServer: nginx\r\nI
```

利用getURL()查看相关信息

- 查看服务器端返回的头信息
- ###列表形式
- h = basicHeaderGatherer()

txtt=getURL("http://www.dataguru.cn/",headerfunction = h$update)

names(h$value())

h$value()

```
> k=getURL("http://www.dataguru.cn/",headerfunction = h$update)
> h$value()
                        Server                                  Date
                       "nginx" "Tue, 05 Aug 2014 03:40:08 GMT"
                  Content-Type                        Content-Length
                    "text/html"                              "225561"
                 Last-Modified                        Connection
"Tue, 05 Aug 2014 03:10:01 GMT"                        "keep-alive"
                          Vary                                  ETag
               "Accept-Encoding"                "\"53e04b09-37119\""
                 Accept-Ranges                                status
                         "bytes"                               "200"
              statusMessage
                          "OK"
```

利用getURL()查看相关信息

- 查看curl请求的访问信息
- curl = getCurlHandle()

d=getURL("http://www.dataguru.cn/", curl = curl)

getCurlInfo(curl)$response.code

getCurlInfo(curl)

```
> getCurlInfo(curl)
$effective.url
[1] "http://www.dataguru.cn/"

$response.code
[1] 200

$total.time
[1] 0.39

$namelookup.time
[1] 0.016

$connect.time
[1] 0.063

$pretransfer.time
[1] 0.063

$size.upload
[1] 0
```

武装自己的header

- myheader <- c(

"User-Agent"="Mozilla/5.0 (Windows; U; Windows NT 5.1; zh-CN; rv:1.9.1.6) ",

"Accept"="text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8",

"Accept-Language"="en-us",

"Connection"="keep-alive",

"Accept-Charset"="GB2312,utf-8;q=0.7,*;q=0.7"

)

- 如何确认自己的header提交上去了呢？

除了header还有什么

- 可设参数listCurlOptions()
- 可设参数170余个！！
- 下节课会讲解几个常用参数的设置。

getForm

- 探寻搜索原理
  - 以百度搜索”RCurl”为例
- 提取关键字符
- 替换成新的搜索

postForm

- 提交表单
  - 新浪登录的尝试
  - 如何确定信息提交上去了？
- http://www.dataguru.cn/article-873-1.html

炼数成金逆向收费式网络课程

- Dataguru（炼数成金）是专业数据分析网站，提供教育，媒体，内容，社区，出版，数据分析业务等服务。我们的课程采用新兴的互联网教育形式，独创地发展了逆向收费式网络培训课程模式。既继承传统教育重学习氛围，重竞争压力的特点，同时又发挥互联网的威力打破时空限制，把天南地北志同道合的朋友组织在一起交流学习，使到原先孤立的学习个体组合成有组织的探索力量。并且把原先动辄成千上万的学习成本，直线下降至百元范围，造福大众。我们的目标是：低成本传播高价值知识，构架中国第一的网上知识流转阵地。
- 关于逆向收费式网络的详情，请看我们的培训网站 http://edu.dataguru.cn

Thanks

FAQ时间